A general vision model can help with grouping

Three-page pilot on the Kale scan

The current chat assistant inspected the original images of PDF pages **17, 97 and 113** and proposed semantic regions. All seven verse passages were proposed as complete multi-line blocks. Commentary, short lead-ins, footnotes and running furniture were separated.

What this demonstrates: asking a general vision-language model for whole passages gives a useful alternative to a detector trained to propose page elements. In these examples, it can keep a verse together where the detector fragments it into lines.

What it does not establish: this was an interactive pass in the ongoing conversation, with access to the previous investigation. It was not a fresh, independent API invocation. The assistant estimated the rectangles visually and has not measured repeatability, per-page API cost, latency, or cross-book accuracy. No Claude or Gemini calls were made.

PDF page	V3 boxes	Vision boxes	Whole verse blocks
17	15	9	2
97	16	8	2
113	22	9	3

Region counts are descriptive, not accuracy scores. Header/watermark policies and grouping granularity differ. Red and amber overlays reveal unassigned and duplicated foreground; the mask uses the exclusions documented in the earlier experiment.

Practical design: use the vision model to propose passage groups and reading order, then use pixels or detected lines to refine the boundaries. Show editable boxes, especially at close verse/commentary transitions. The crowded page 113 illustrates why semantic grouping and exact cropping need separate checks.

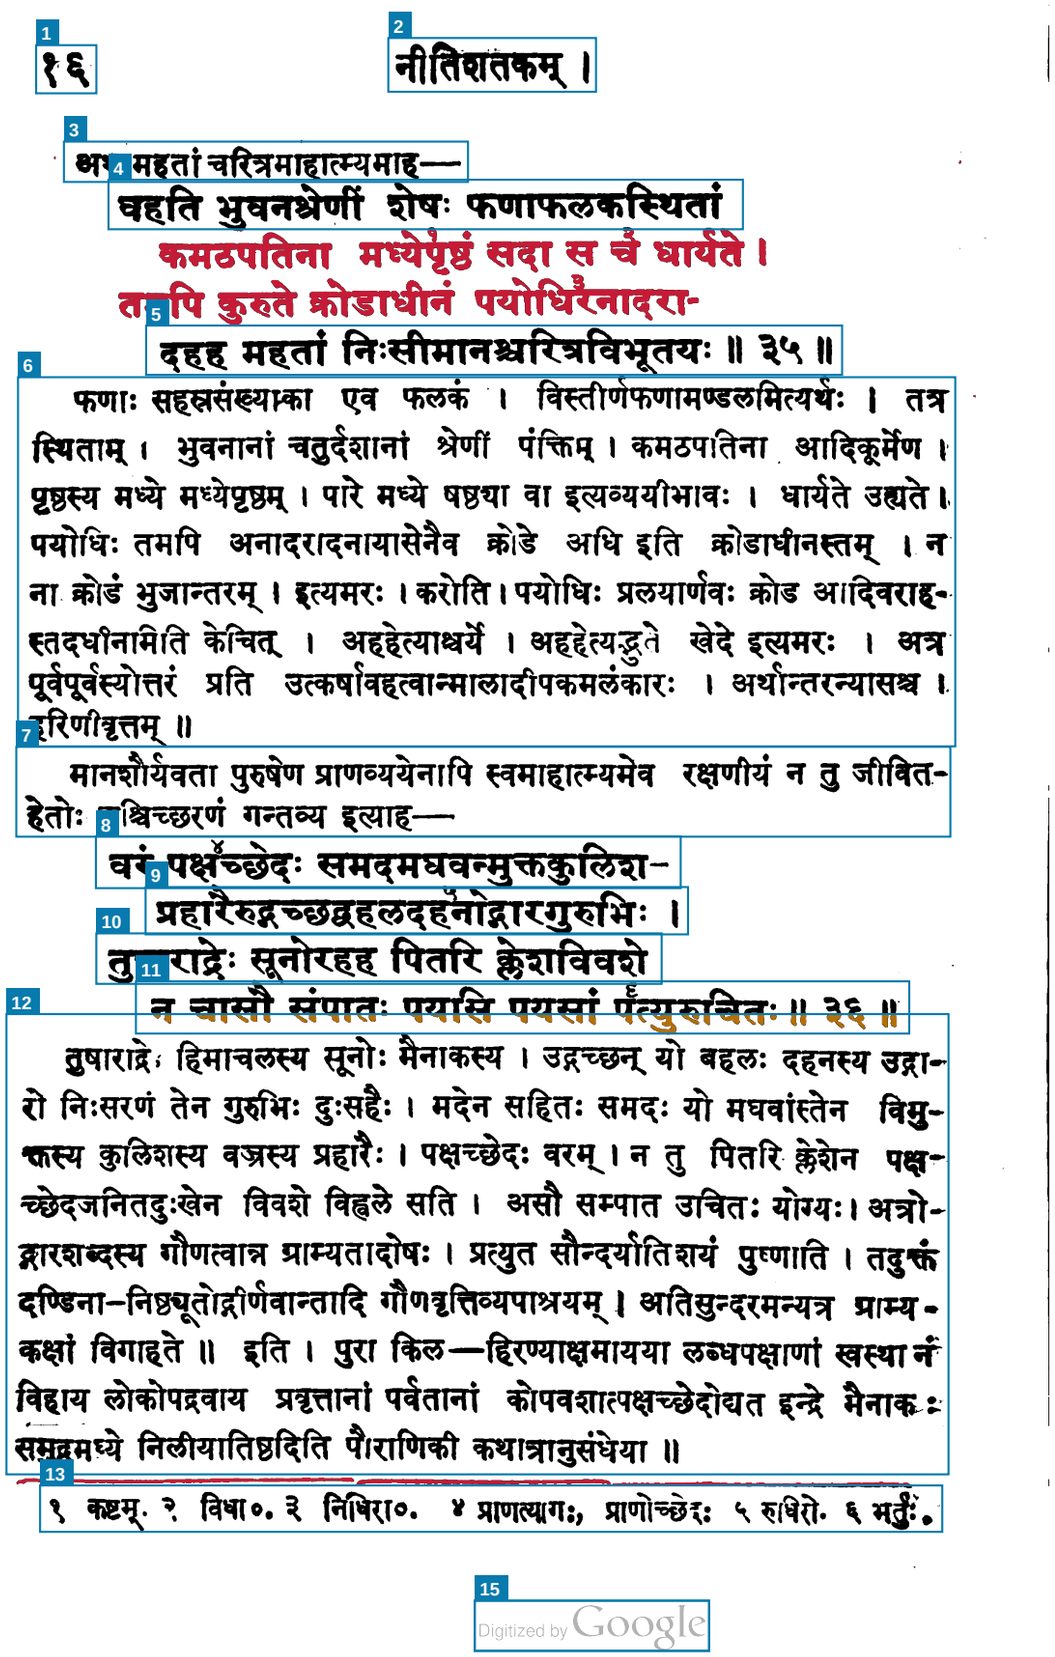
The supplement includes the source PDF, the three input renders, frozen proposals, metrics, a reusable prompt, the previous experiment archive, and a local handoff. No API keys are required to inspect or reproduce these diagrams. A fresh automated provider comparison needs configured model access.

Whole-block vision pilot / PDF page 17

Frozen interactive proposals. Red = uncovered ink; amber = ink covered by overlapping boxes.

Saved PP-DocLayoutV3 / threshold 0.30

15 boxes | 92.39% measured ink covered



१६

नीतिशतकम् ।

अथ महतां चरित्रमाहात्म्यमाह—

वहति भुवनश्रेणीं शेषः फणाफलकस्थितां
कमठपतिना मध्येपृष्ठं सदा स चै धार्यते ।
तमपि कुरुते क्रोडाधीनं पयोधिरनादरा-
दहह महतां निःसीमानश्चरित्रविभूतयः ॥ ३५ ॥

फणाः सहस्रसंख्याका एव फलकं । विस्तीर्णफणामण्डलमित्यर्थः । तत्र स्थिताम् । भुवनानां चतुर्दशानां श्रेणीं पंक्तिम् । कमठपतिना आदिकूर्मेण । पृष्ठस्य मध्ये मध्येपृष्ठम् । पारे मध्ये षष्ठ्या वा इत्यव्ययीभावः । धार्यते उह्यते । पयोधिः तमपि अनादरादनायासेनैव क्रोडे अधि इति क्रोडाधीनस्तम् । न ना क्रोडं भुजान्तरम् । इत्यमरः । करोति । पयोधिः प्रलयार्णवः क्रोड आदिवराह-स्तदधीनामिति केचित् । अहहेत्याश्चर्ये । अहहेत्यद्भुते खेदे इत्यमरः । अत्र पूर्वपूर्वस्योत्तरं प्रति उत्कर्षावहत्वान्मालादीपकमलंकारः । अर्थान्तरन्यासश्च । हरिणीवृत्तम् ॥

मानशौर्यवता पुरुषेण प्राणव्ययेनापि स्वमाहात्म्यमेव रक्षणीयं न तु जीवित-हेतोः कश्चिच्छरणं गन्तव्य इत्याह—

वरं पक्षच्छेदः समदमघवन्मुक्तकुलिश-
प्रहारैरुद्गच्छद्बहलदहनोद्गारगुरुभिः ।
तुषाराद्रेः सूनोरहह पितरि क्लेशविवशे
न चासौ संपातः पयसि पयसां पत्युरुचितः ॥ ३६ ॥

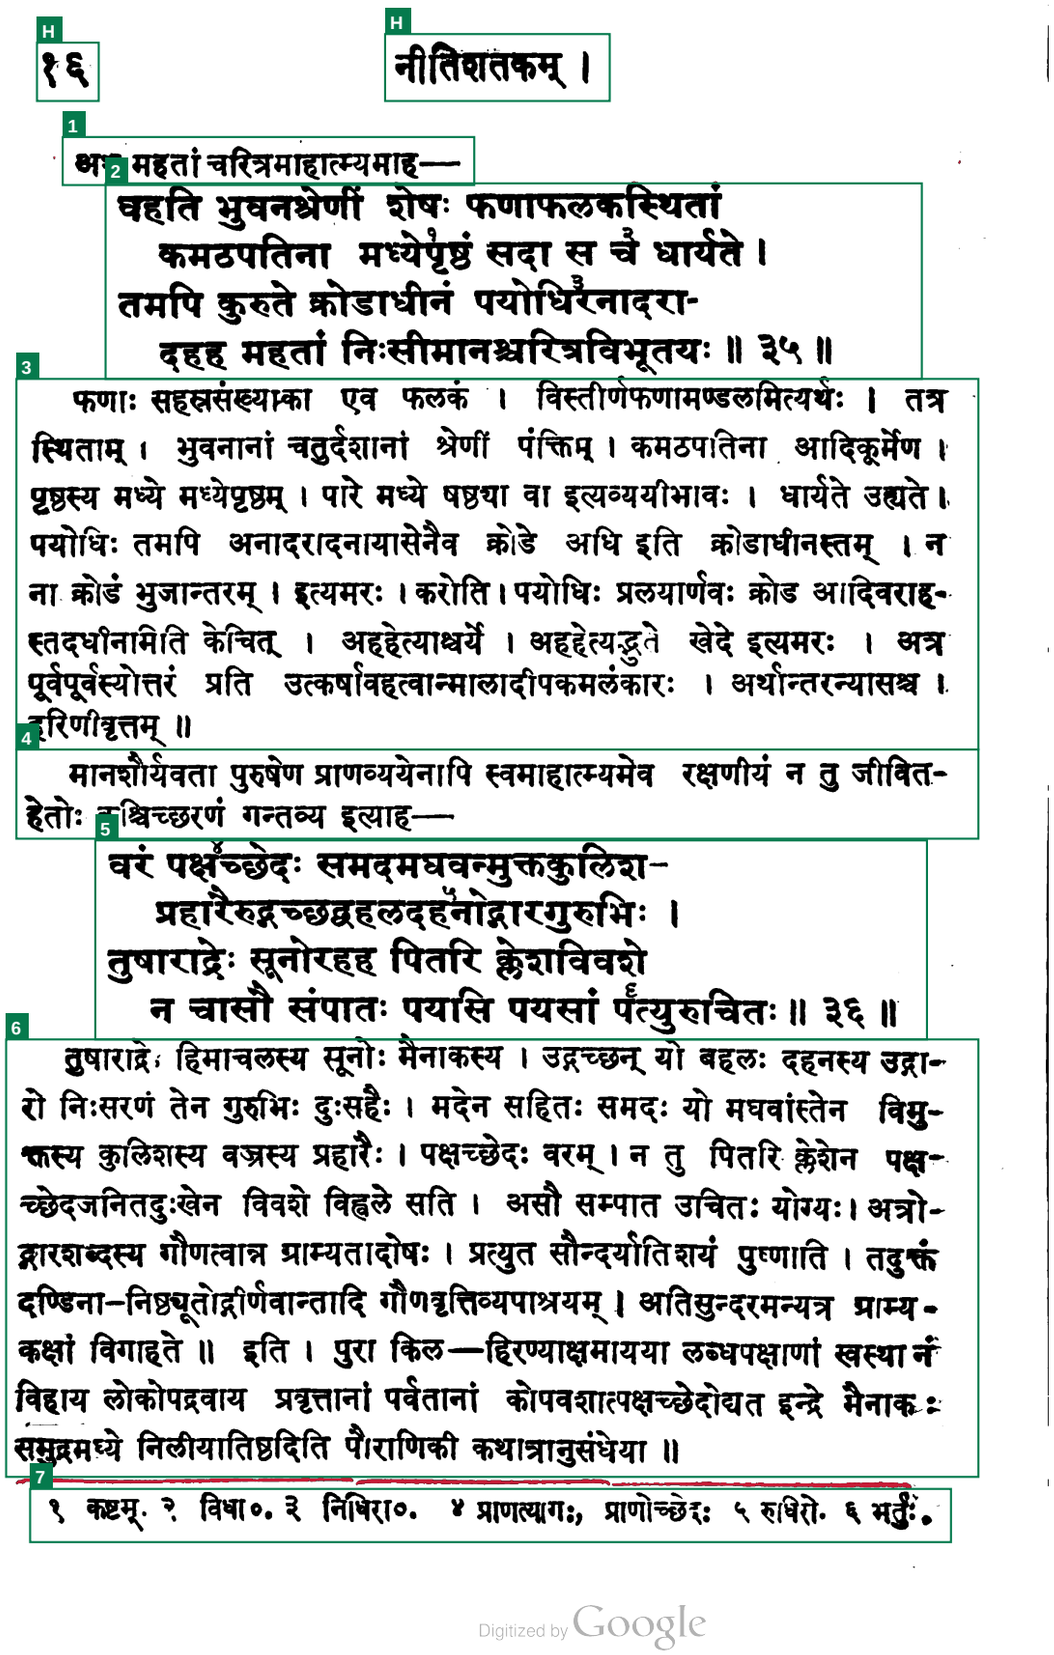
तुषाराद्रेः हिमाचलस्य सूनोः मैनाकस्य । उद्गच्छन् यो बहलः दहनस्य उद्गारो निःसरणं तेन गुरुभिः दुःसहैः । मदेन सहितः समदः यो मघवांस्तेन विमुक्तस्य कुलिशस्य वज्रस्य प्रहारैः । पक्षच्छेदः वरम् । न तु पितरि क्लेशेन पक्षच्छेदजनितदुःखेन विवशे विह्वले सति । असौ सम्पात उचितः योग्यः । अत्रोद्गारशब्दस्य गौणत्वान्न ग्राम्यतादोषः । प्रत्युत सौन्दर्यातिशयं पुष्णाति । तदुक्तं दण्डिना—निष्ठ्यूतोद्गीर्णवान्तादि गौणवृत्तिव्यपाश्रयम् । अतिसुन्दरमन्यत्र ग्राम्यकक्षां विगाहते ॥ इति । पुरा किल—हिरण्याक्षमायया लब्धपक्षाणां स्वस्थानं विहाय लोकोपद्रवाय प्रवृत्तानां पर्वतानां कोपवशात्पक्षच्छेदोद्यत इन्द्रे मैनाकः समुद्रमध्ये निलीयातिष्ठदिति पौराणिकी कथात्रानुसंधेया ॥

१ कष्टम्. २ विधा०. ३ निधिरा०. ४ प्राणत्यागः, प्राणोच्छेदः ५ रुधिरो. ६ भर्तुः.

Digitized by Google

Current assistant / interactive vision pass

9 boxes | 2 whole verse blocks | 98.86% measured ink covered



१६

नीतिशतकम् ।

अथ महतां चरित्रमाहात्म्यमाह—

वहति भुवनश्रेणीं शेषः फणाफलकस्थितां
कमठपतिना मध्येपृष्ठं सदा स चै धार्यते ।
तमपि कुरुते क्रोडाधीनं पयोधिरनादरा-
दहह महतां निःसीमानश्चरित्रविभूतयः ॥ ३५ ॥

फणाः सहस्रसंख्याका एव फलकं । विस्तीर्णफणामण्डलमित्यर्थः । तत्र स्थिताम् । भुवनानां चतुर्दशानां श्रेणीं पंक्तिम् । कमठपतिना आदिकूर्मेण । पृष्ठस्य मध्ये मध्येपृष्ठम् । पारे मध्ये षष्ठ्या वा इत्यव्ययीभावः । धार्यते उह्यते । पयोधिः तमपि अनादरादनायासेनैव क्रोडे अधि इति क्रोडाधीनस्तम् । न ना क्रोडं भुजान्तरम् । इत्यमरः । करोति । पयोधिः प्रलयार्णवः क्रोड आदिवराह-स्तदधीनामिति केचित् । अहहेत्याश्चर्ये । अहहेत्यद्भुते खेदे इत्यमरः । अत्र पूर्वपूर्वस्योत्तरं प्रति उत्कर्षावहत्वान्मालादीपकमलंकारः । अर्थान्तरन्यासश्च । हरिणीवृत्तम् ॥

मानशौर्यवता पुरुषेण प्राणव्ययेनापि स्वमाहात्म्यमेव रक्षणीयं न तु जीवित-हेतोः कश्चिच्छरणं गन्तव्य इत्याह—

वरं पक्षच्छेदः समदमघवन्मुक्तकुलिश-
प्रहारैरुद्गच्छद्बहलदहनोद्गारगुरुभिः ।
तुषाराद्रेः सूनोरहह पितरि क्लेशविवशे
न चासौ संपातः पयसि पयसां पत्युरुचितः ॥ ३६ ॥

तुषाराद्रेः हिमाचलस्य सूनोः मैनाकस्य । उद्गच्छन् यो बहलः दहनस्य उद्गारो निःसरणं तेन गुरुभिः दुःसहैः । मदेन सहितः समदः यो मघवांस्तेन विमुक्तस्य कुलिशस्य वज्रस्य प्रहारैः । पक्षच्छेदः वरम् । न तु पितरि क्लेशेन पक्षच्छेदजनितदुःखेन विवशे विह्वले सति । असौ सम्पात उचितः योग्यः । अत्रोद्गारशब्दस्य गौणत्वान्न ग्राम्यतादोषः । प्रत्युत सौन्दर्यातिशयं पुष्णाति । तदुक्तं दण्डिना—निष्ठ्यूतोद्गीर्णवान्तादि गौणवृत्तिव्यपाश्रयम् । अतिसुन्दरमन्यत्र ग्राम्यकक्षां विगाहते ॥ इति । पुरा किल—हिरण्याक्षमायया लब्धपक्षाणां स्वस्थानं विहाय लोकोपद्रवाय प्रवृत्तानां पर्वतानां कोपवशात्पक्षच्छेदोद्यत इन्द्रे मैनाकः समुद्रमध्ये निलीयातिष्ठदिति पौराणिकी कथात्रानुसंधेया ॥

१ कष्टम्. २ विधा०. ३ निधिरा०. ४ प्राणत्यागः, प्राणोच्छेदः ५ रुधिरो. ६ भर्तुः.

Digitized by Google

Two whole verses, two lead-ins, two commentary passages and a footnote. The visual pass keeps the verses together, while the detector splits several lines and misses part of the upper verse.

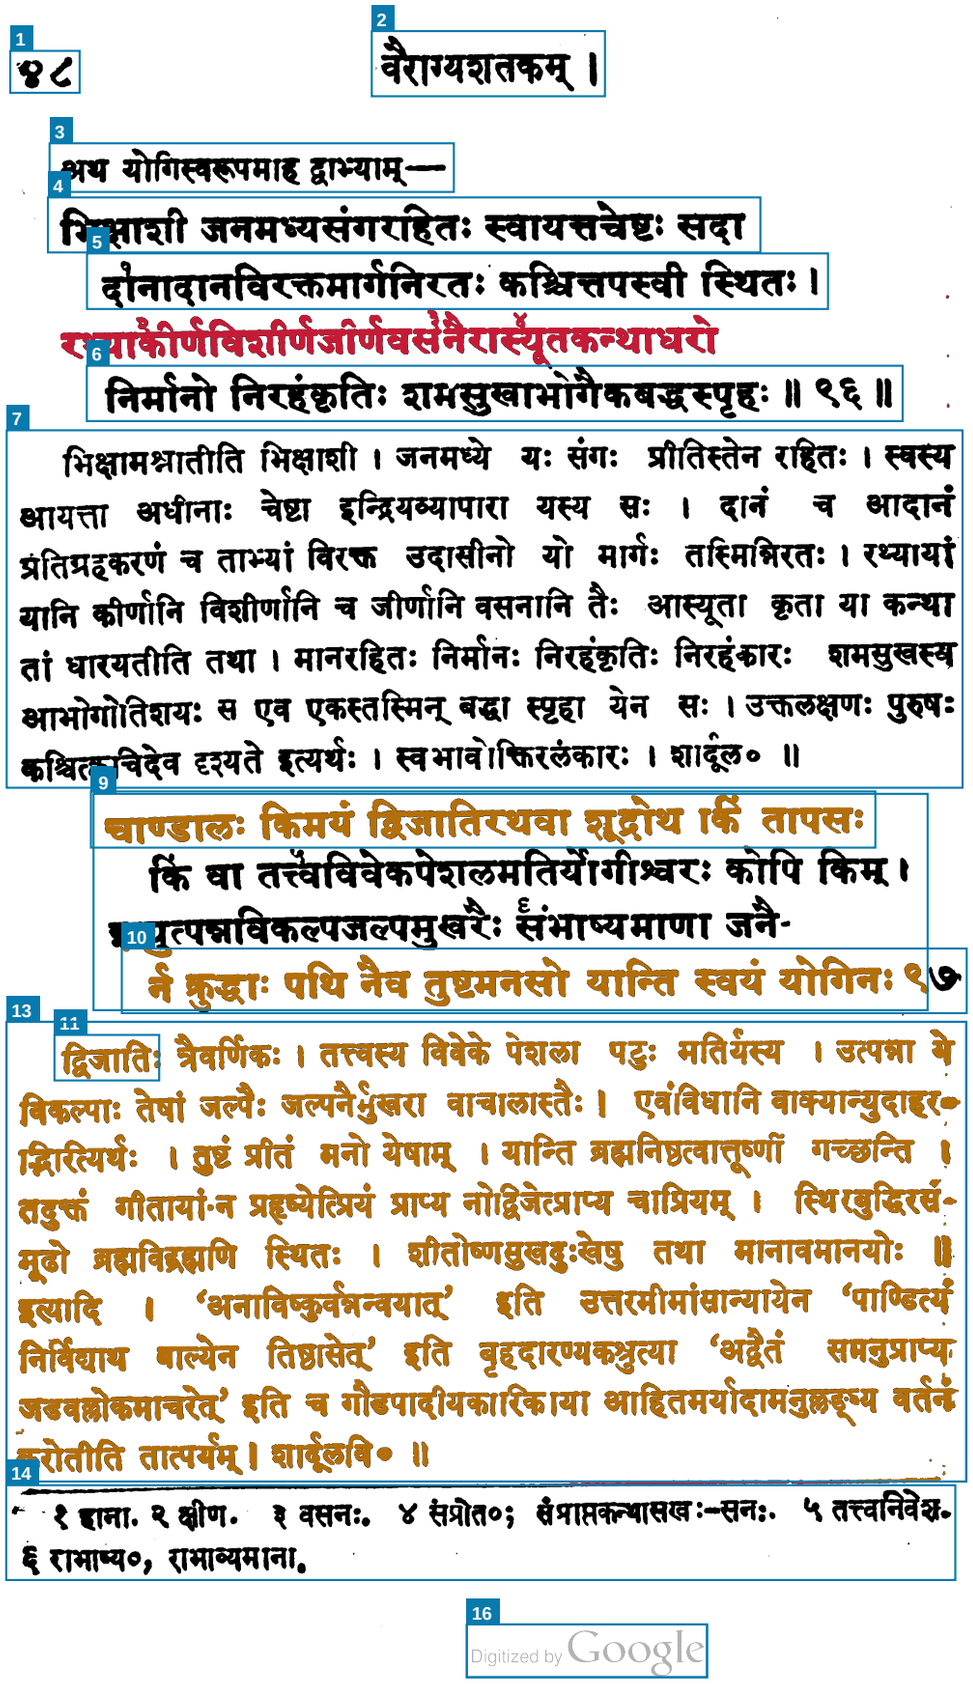
Interactive demonstration, not a blind or repeatable API benchmark. H = furniture; content numbers show proposed reading order.

Whole-block vision pilot / PDF page 97

Frozen interactive proposals. Red = uncovered ink; amber = ink covered by overlapping boxes.

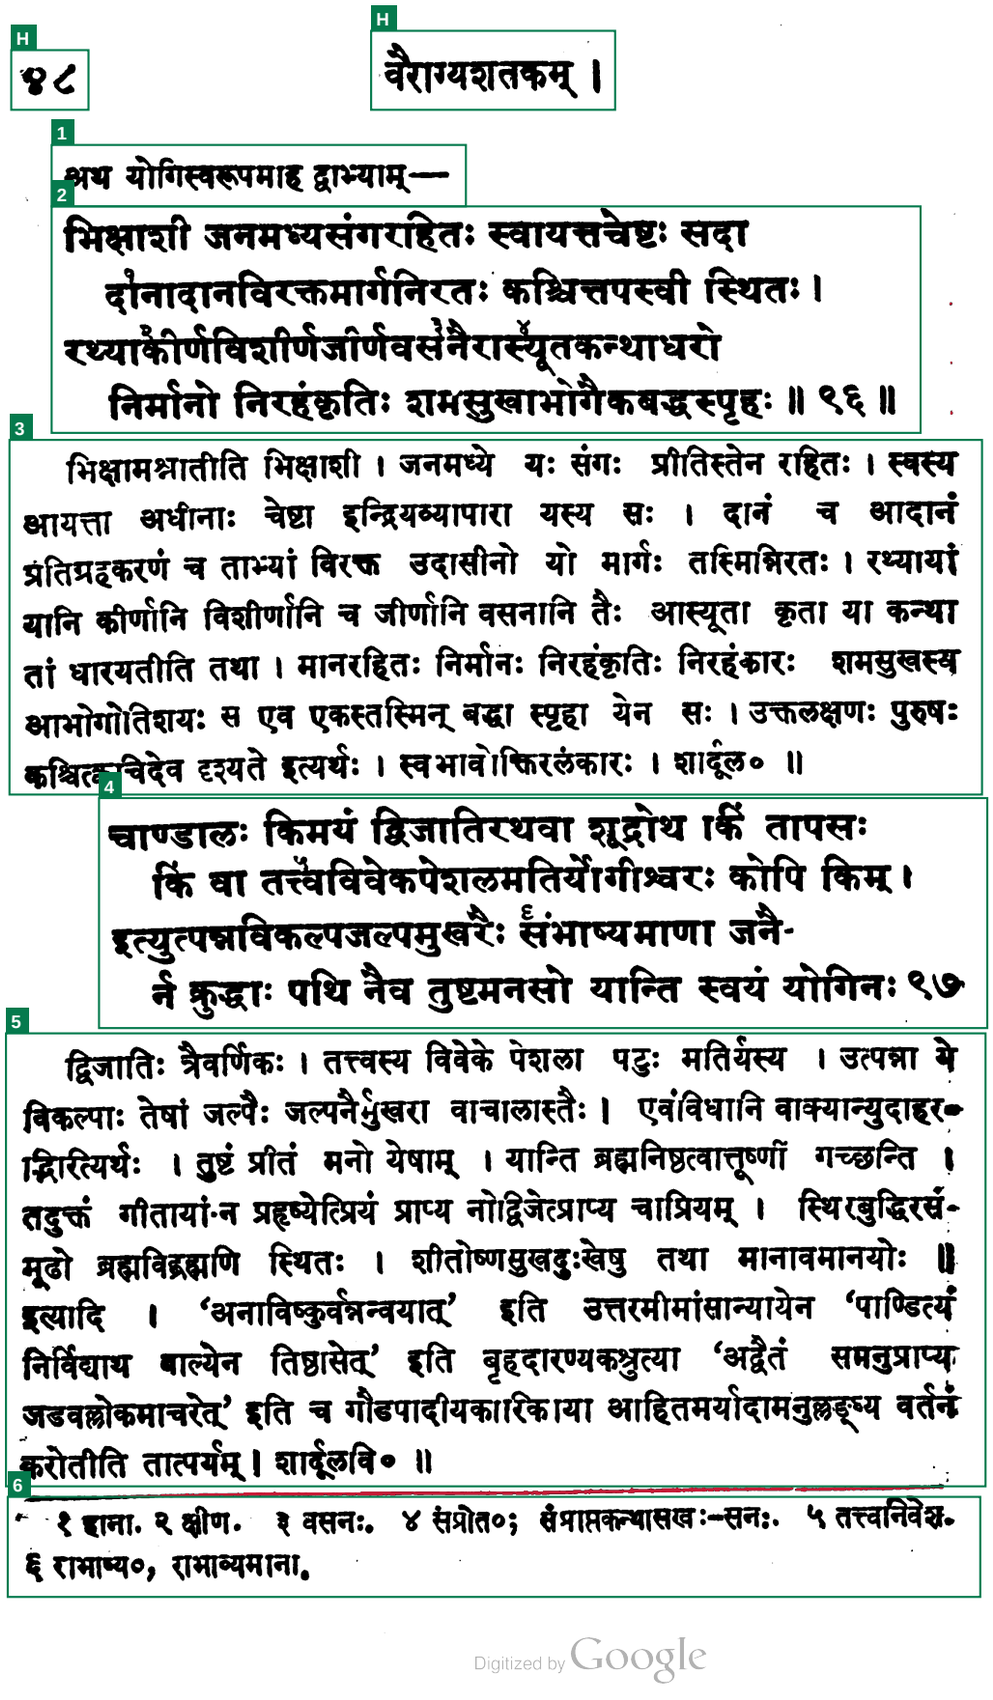
Saved PP-DocLayoutV3 / threshold 0.30

16 boxes | 95.65% measured ink covered



Current assistant / interactive vision pass

8 boxes | 2 whole verse blocks | 99.13% measured ink covered



Two whole verses, one lead-in, two commentary passages and a footnote. The model can use typographic and textual context to group a complete stanza, instead of treating each line independently.

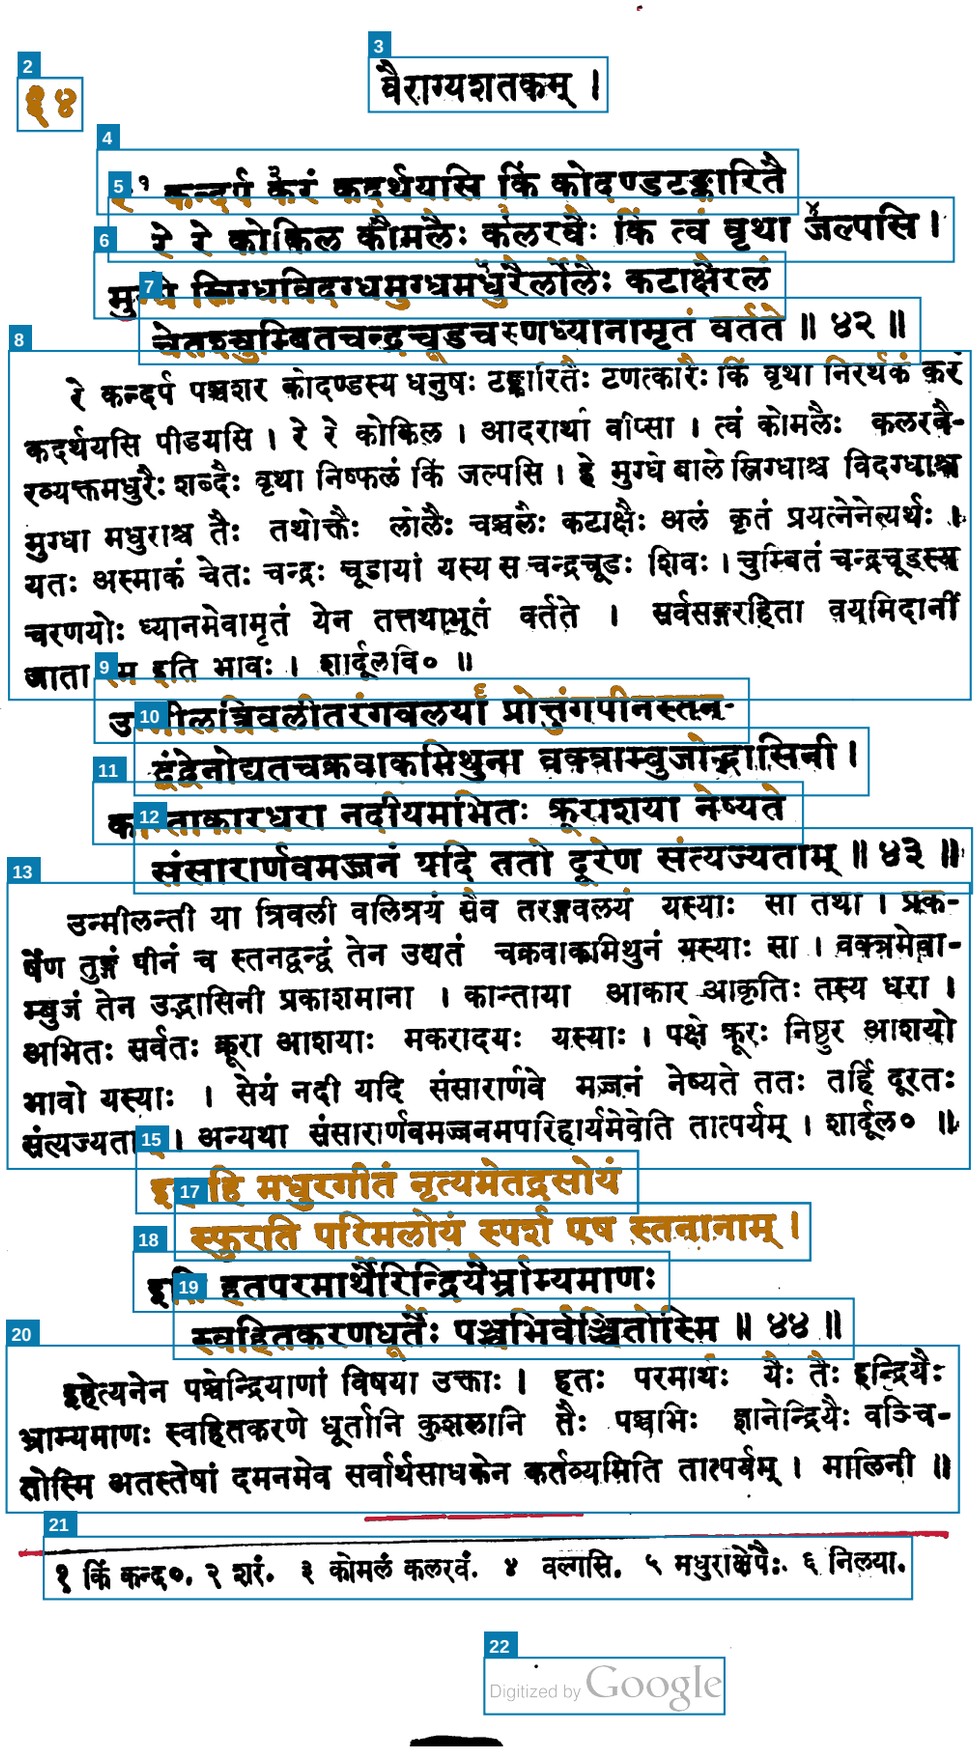
Interactive demonstration, not a blind or repeatable API benchmark. H = furniture; content numbers show proposed reading order.

Whole-block vision pilot / PDF page 113

Frozen interactive proposals. Red = uncovered ink; amber = ink covered by overlapping boxes.

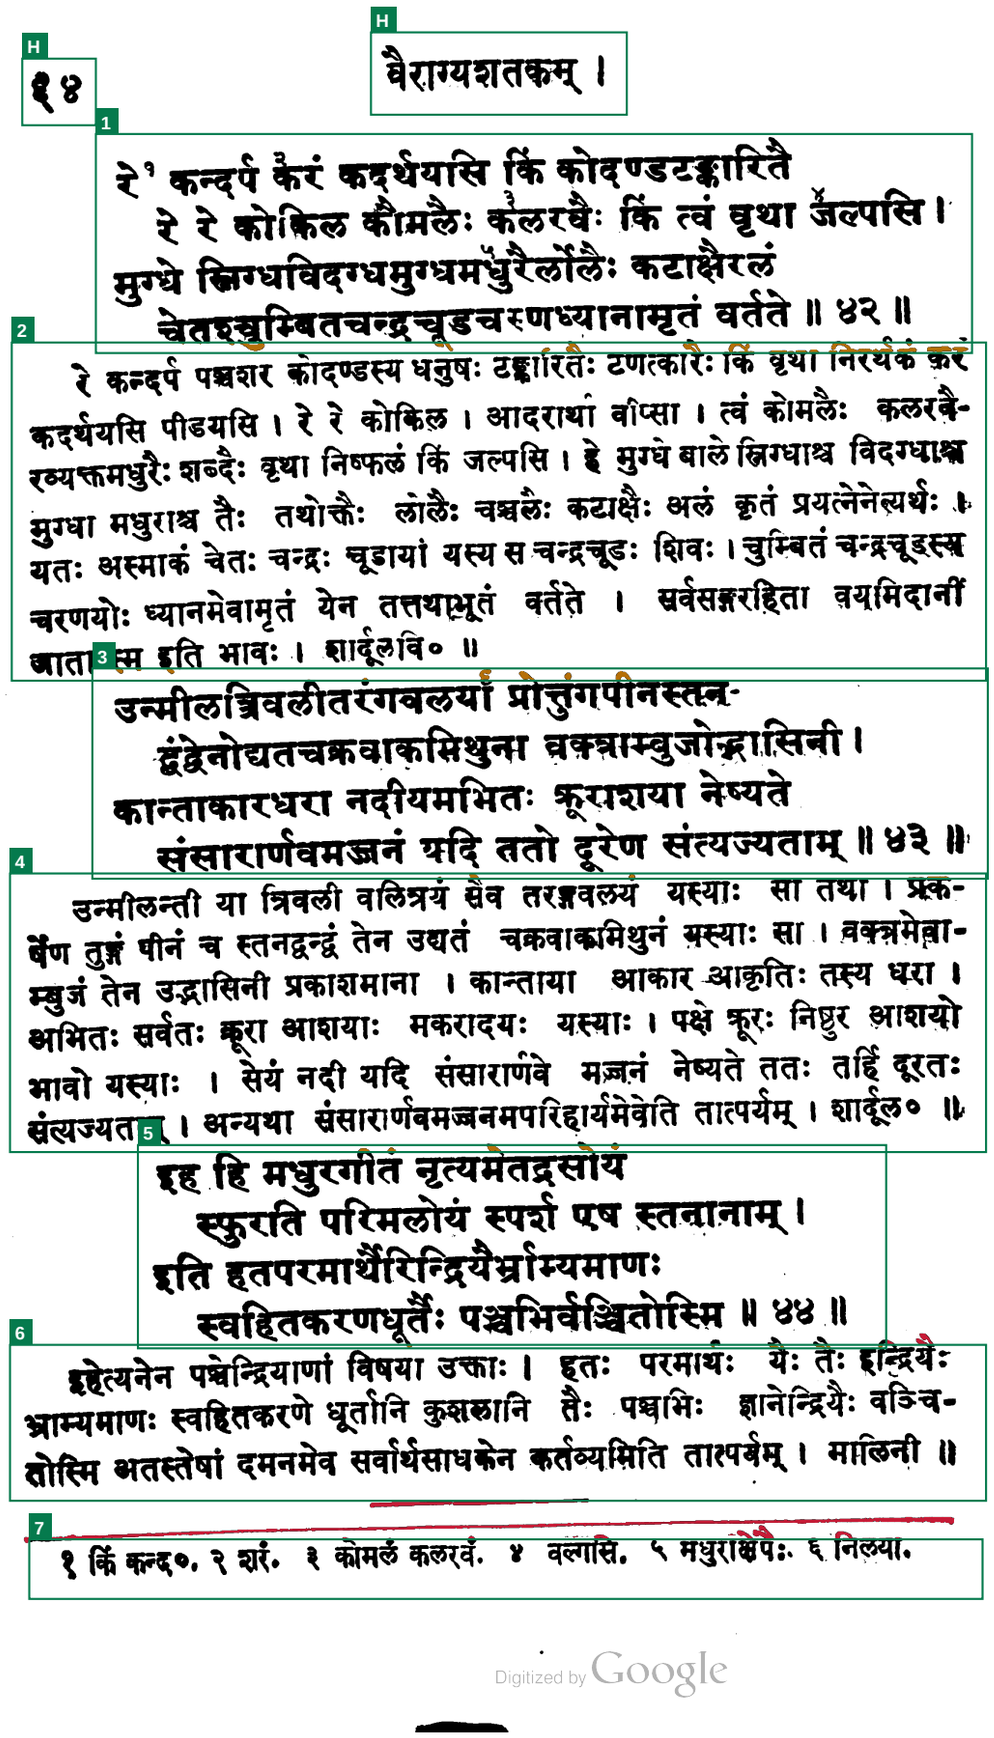
Saved PP-DocLayoutV3 / threshold 0.30

22 boxes | 99.40% measured ink covered



Current assistant / interactive vision pass

9 boxes | 3 whole verse blocks | 98.76% measured ink covered



Three whole verses alternating with commentary. The estimated rectangles overlap slightly at crowded verse/commentary boundaries. Grouping can improve while exact localization still needs refinement.

Interactive demonstration, not a blind or repeatable API benchmark. H = furniture; content numbers show proposed reading order.